AI Guardrails практика

Богдан Минко
ML Engineer @ Hivetrace
AI Talent Hub, ITMO

Что вы узнаете

1. Как поставить guardrails для ПД,
2. Как ловить промпт-атаки и вредоносный контент
3. Что если все это может одна модель? (и это не LLM)